

PS1 - Equipo 03

Catalina Leal Rojas, Lucas Daniel Carrillo Aguirre, Lucas Eduardo Veras
Costa, Maria Paula Basto Lozano

7 de septiembre de 2025

El link del repositorio es: https://github.com/mbastol06/PS1_Equipo3

1. Introducción

Poner acá la introducción

2. Datos

■ Fuente de los datos:

La información utilizada para este estudio fue obtenida desde el “*Reporte de Medición de Pobreza Monetaria y Desigualdad*”, correspondiente a la Gran Encuesta Integrada de Hogares (GEIH) hecha por el Departamento Administrativo Nacional de Estadística (DANE) en el año 2018.

Este reporte busca hacer una caracterización de la población sobre rubros como los ingresos, el estrato, la edad, el sexo, la cantidad de horas trabajadas, entre otros.

■ Web Scraping:

Los datos necesarios para el análisis están consignados en una página web (https://ignaciomsarmiento.github.io/GEIH2018_sample/) que dirige a diez enlaces diferentes para cada una de las particiones de la base de datos original. Así, la forma más pertinente para extraer los datos resultó ser el método de raspado web o web scraping. Sin embargo, debido a que la página está construida en formato Java Script, las instrucciones revisadas a lo largo del curso para este método fueron insuficientes.

Para acceder a la fuente cruda de las tablas de cada uno de los diez chunks de datos fue necesario hacer una revisión de los elementos de la página por medio de la herramienta “Inspección” integrada en el explorador Google Chrome. Allí, en el panel de elementos en la ventana de “Red” se identificó un apartado con la fuente HTML

de la página, que dirigía al mismo enlace de arriba, con un “[pages/geih_page_1.html](#)” adicional para la primera página. Agregando esa terminación sobre cada una de las otras nueve páginas y se hizo entonces un web scraping común para un HTML con tablas. Este proceso de extracción se hizo iterativamente sobre cada uno de los enlaces y se compiló en una tabla combinada con 32,177 observaciones para 178 variables diferentes.

■ Limpieza de los datos:

Para hacer que los datos fuesen adecuados para hacer el análisis central de este trabajo, a saber, la modelación del salario por hora en esta muestra poblacional específica, fue necesario hacer un proceso de depuración e imputación de datos de la siguiente manera.

Primero, se redujo la muestra poblacional a los individuos mayores a 18 años de edad, que son los que están en edad de trabajar y tienen datos de salario disponibles; así como también se eliminaron los individuos que trabajaran por cuenta propia toda vez que la contabilidad de sus ingresos es inexacta y difícil de rastrear. Esto también implicó la eliminación de observaciones que tuvieran salarios de cero o nulos.

Segundo, se eliminaron, de la muestra inicial de 178, todas las variables que en cada una de las observaciones tuvieran consistentemente valores faltantes o valores idénticos. Además, se desestimaron todas las variables que tuvieran valores faltantes en más del 60 % de las observaciones. Estos dos pasos fueron necesarios para evitar utilizar observaciones y variables que podían no aportar nada a la base más que ruido.

Después de estos dos pasos, se hizo la imputación de datos para cada uno de los valores faltantes en la base de datos resultante. Esto se hizo por medio de dos métodos. El primero implicó identificar todas las variables categóricas de la muestra, que eran todas aquellas que se correspondían con la indagación de salarios de los individuos (por ejemplo, preguntas de respuestas binarias de sí o no, o de respuestas con un rango del 1 al 3). Luego de que se hizo esto, se calculó la moda de las observaciones en esas variables para todos los individuos que compartieran el mismo estrato social, y los valores faltantes se imputaron con ella. Esto, entendiendo que es más probable que individuos que compartan condiciones socioeconómicas similares puedan tener características en sus ingresos comparables.

El segundo método implicó identificar las variables numéricas, que eran todas aquellas que tenían valores en magnitud monetaria, como los ingresos, los auxilios y las deducciones. A los valores faltantes de estas variables se les aplicó el método de K Vecinos más Cercanos (*o K-Nearest Neighbors*) que busca las similitudes entre las observaciones de la base e identifica, por medio de un algoritmo de aprendizaje supervisado, los k vecinos más cercanos para cada una (en este caso los 5 más cercanos). Así, con los valores de los vecinos, se imputaron las observaciones con valores faltantes en dichas variables.

Lo último que se hizo para la organización de la base de datos fue reemplazar con los valores del percentil 97.5 todos los valores de las observaciones de las variables

de ingreso que se ubicaran más allá de ese umbral. Esto para evitar que esas variables, que suelen tener una dispersión importante en ese último segmento poblacional, tuviesen un impacto indeseado sobre la estadística descriptiva de la muestra.

■ **Estadística descriptiva de los datos:**


Tabla

Cuadro 1. Estadísticas descriptivas

Variable	N	Media	Desv. Est.	Min	Max
Salario mensual	9,892	1,610,062	1,537,098	20,000	7,892,291
Salario por hora	9,892	8,121.29	8,099.11	326.67	41,470.34
$\ln(\text{Salario})$	9,892	8.71	0.69	5.79	10.63
Edad	9,892	36.24	12.02	18.00	86.00
Mujer (1 = Sí)	9,892	0.50	0.50	0.00	1.00
Trabaja en microempresa (1 = Sí)	9,892	0.23	0.42	0.00	1.00
Trabajo formal (1 = Sí)	9,892	0.77	0.42	0.00	1.00

Histogramas

Figura 1. Distribuciones del salario por hora y su logaritmo natural



Nota: En el panel izquierdo se encuentra la distribución del salario por hora en pesos. En el panel derecho se encuentra la distribución del logaritmo natural del salario por hora. La línea roja es la mediana y la azul es la media.

3. Perfil edad-salario

En esta sección analizaremos la relación entre el perfil edad-salario. En primer lugar, es importante discutir qué medida de ingreso utilizar. La base de datos de la GEIH incluye diversas medidas, como ingreso por primas monetarias, ingreso mensual, ingreso usual en el mes e ingreso efectivo en el mes, entre otras.

En los estudios que analizan el perfil salarial de edad, es común emplear el ingreso por hora, ya que permite aislar el efecto de las horas trabajadas en el mes, lo cual podría sesgar los resultados. Asimismo, suele utilizarse la variable de ingreso en logaritmos, lo que mejora la interpretabilidad del coeficiente estimado, que pasaría a representar cuánto impacta, en términos porcentuales, una unidad adicional de la variable independiente sobre el ingreso, en este caso un año adicional en la edad.

Se estimó el siguiente modelo para identificar el perfil edad-salario de las observaciones de la muestra.

$$\ln w_i = \beta_1 + \beta_2 Age_i + \beta_3 Age_i^2 + u_i \quad (1)$$

Donde w_i es el ingreso salarial por hora del individuo i y Age_i es su edad. Se realizó la estimación del modelo con las diferentes medidas de ingreso salarial real y nominal por hora:

Cuadro 2. Perfil de salario-edad

	<i>Dependent variable:</i>	
	log(y_salary_m.hu)	log(y_total_m.ha)
	(1)	(2)
age	0.059*** (0.003)	0.066*** (0.003)
I(age^2)	-0.001*** (0.00004)	-0.001*** (0.00004)
Constant	7.407*** (0.064)	7.393*** (0.065)
Observations	9,892	9,892
R ²	0.040	0.045
Adjusted R ²	0.040	0.045
Residual Std. Error (df = 9889)	0.671	0.677
F Statistic (df = 2; 9889)	206.012***	235.041***
<i>Note:</i> *p<0.1; **p<0.05; ***p<0.01		

■ Interpretación de los coeficientes:

De acuerdo con los resultados de las dos regresiones, el perfil salarial según la edad tienen la misma forma funcional, es decir una curva cóncava. En concreto, el término lineal de la edad muestra el efecto directo de “sumar un año”, mientras que el término cuadrático ($edad^2$) captura cómo que existen efectos diferenciados sobre el salario en

edades diferentes de la vida, es decir que la relación entre la edad y el salario no es lineal.

El sumar un año de edad incrementa 5.9 % y 6.6 % el salario (el efecto directo) tomando como el salario real y nominal por hora respectivamente. Ambos coeficientes estimados son significativos estadísticamente y positivos lo que indica en primera instancia un efecto directo positivo de la edad sobre el salario. El coeficiente relacionado con la edad al cuadrado captura esa relación no lineal. Tanto para el modelo con el salario real como el nominal el coeficiente de la edad cuadrática es negativo lo que indica la concavidad de la relación, es decir que hasta un punto la relación entre edad y salario o es positiva y luego es negativa, en ambos modelos el término es negativo y estadísticamente significativo.

Para estimar la semieleasticidad de la edad sobre el logaritmo del salario solucionamos la condición de primer orden. Luego un año adicional de edad aumenta porcentualmente el salario en:

$$100 \times (\beta_2 + 2 \times \beta_3 \times edad) \%$$

La semieleasticidad de para las edades de 18 , 25, 45 y 50 años se presentan en el cuadro 3. Como se observa, entre más joven más aporta un año más de edad en el incremento porcentual del salario, va decreciendo e incluso se vuelve negativo el aporte desde edad más avanzada lo que se denomina edad pico.

Cuadro 3. Semielasticidad del salario sobre el ingreso

Edad	Salario Real	Salario Nominal
18	3.588	3.957
25	2.676	2.927
35	1.372	1.456
45	0.069	-0.015
50	-0.582	-0.750

El coeficiente constante para ambos modelos es positivo y significativo, y representa el valor del logaritmo del salario cuando la edad es cero. Aunque este valor no tiene una interpretación económica directa, no se trabaja con 0 años, por lo que es el término que ajusta el modelo para la relación entre edad y salario dentro del rango de edades observado en la muestra.

■ Ajuste de la muestra:

Para analizar el ajuste de los modelos dentro de la muestra, se presenta los siguientes estadísticos como el error estándar (RSE), el error cuadrático medio (RMSE), el R^2 ajustado, estadístico F y criterios de información Akaike (AIC) y bayeciano (BIC).

Los resultados muestran que ambos modelos ofrecen un desempeño explicativo limitado pero estadísticamente significativo. El coeficiente de determinación ajustado R^{2*} es de 0.040 en el modelo del salario real y de 0.045 en el del salario nominal, lo que

Cuadro 4. Medidas de ajuste para los modelos de salario por edad


Modelo	RSE	RMSE	R^2*	F	AIC	BIC
Salario real	0.671	0.671	0.040	206.012	20186.076	20214.874
Salario nominal	0.677	0.677	0.045	235.041	20360.186	20388.984

indica que aproximadamente el 4–4,5 % de la variación en el logaritmo del salario se explica únicamente por la edad y su cuadrado. El error estándar residual (RSE), que estima la desviación promedio de los residuos ajustando por los grados de libertad, es de 0,671 y 0,677 respectivamente, mientras que el RMSE, que se calcula sobre el total de observaciones, coincide numéricamente con esos valores debido al gran tamaño muestral. Ambos modelos presentan un F estadístico alto y significativo (206.0 y 235.0), que el modelo es globalmente estadísticamente significativo. Finalmente, los criterios de información AIC y BIC son menores en el modelo con salario nominal, lo que sugiere que este ofrece un ajuste más eficiente penalizando la complejidad del modelo.

■ **Gráfico de ingreso salarial, edad pico y su intervalo de confianza:**

A continuación se presenta el gráfico de los valores predichos con cada modelo:

Figura 2. Gráfico del logaritmo de salarios predichos, intervalo de confianza y edad pico



La edad pico se refiere a la edad en la cual el logaritmo del salario alcanza su máximo. Y se obtiene derivando la función del logaritmo del salario e igualando a cero , es

decir que la edad pico se calcula como:

$$edad_pico = -\frac{\beta_2}{2\beta_3}$$

Luego, para cada modelo la edad pico es:


- **Modelo salario real:** 45.53
- **Modelo salario nominal:** 44.89

Luego por bootstrap no paramétrico se estimaron las edades pico para cada modelo con mil remuestreos con reemplazo (R). En cada réplica se re estimó cada modelo obteniendo los coeficientes y luego calculando la edad pico para las R repeticiones. A partir de la distribución empírica de las R edades pico, se calcularon los intervalos de confianza al 95 % con el método de percentil, es decir que los límites corresponden a los cuartiles 2.25 % y 97.5 % de la distribución bootstrap de la edad pico. Los respectivos intervalos de confianza son:

- **Modelo salario real:** (43.74 , 46.21)
- **Modelo salario nominal:** (44.25 , 47.05)

La figura muestra, para cada modelo (nominal y real), la distribución bootstrap de la edad pico: el histograma en azul claro representa la frecuencia de las edades pico re-muestreadas y la curva en azul oscuro es la densidad kernel asociada. Además se agregó: la media de la edad pico por bootstrap para cada modelo, que es representado con la línea vertical morada ; y, los intervalos de confianza para cada modelo en la línea punteada gris. En conjunto, la gráfica permite comparar visualmente la localización y la dispersión de las edades pico entre ambos modelos, dado las densidades se solapan y los intervalos percentiles son similares, se la evidencia indica que las edades pico no difieren de forma sustantiva.

Figura 3. Distribución estimada e intervalos de confianza edad pico



4. La brecha género-salario

En esta sección analizaremos la relación entre ingresos y género femenino. En primer lugar, es importante discutir qué medida de ingreso utilizar. La base de datos de la GEIH incluye diversas medidas, como ingreso por primas monetarias, ingreso mensual, ingreso usual en el mes e ingreso efectivo en el mes, entre otras.

En los estudios que analizan la brecha salarial entre hombres y mujeres, es común emplear el ingreso por hora, ya que permite aislar el efecto de las horas trabajadas en el mes, lo cual podría sesgar los resultados. Asimismo, suele utilizarse la variable de ingreso en logaritmos, lo que mejora la interpretabilidad del coeficiente estimado, que pasaría a representar cuánto impacta, en términos porcentuales, una unidad adicional de la variable independiente sobre el ingreso.

También es importante señalar que nos interesa comparar únicamente a hombres y mujeres que trabajan. Por lo tanto, el análisis se centra en los individuos ocupados de la muestra.

Inicialmente estimamos el siguiente modelo:

$$\log(\omega) = \beta_0 + \beta_1 Female + u \quad (2)$$

El Cuadro 5 presenta los resultados de la estimación por mínimos cuadrados ordinarios utilizando diversas medidas de ingreso. *ysalarym* corresponde al ingreso nominal de la ocupación principal, *ysalarymha* al salario por hora de la ocupación principal, *yingLabm* al ingreso proveniente de todas las ocupaciones, *ytotalm* al ingreso total proveniente de ocupaciones e ingresos independientes, y *ytotalmha* al ingreso total de ocupaciones e independientes medido por hora.

Cuadro 5. Resultados del modelo incondicional

	Variable dependiente:				
	log(ysalarym)	log(ysalarymha)	log(yingLabm)	log(ytotalm)	log(ytotalmha)
	(1)	(2)	(3)	(4)	(5)
female	-0.149*** (0.015)	-0.045*** (0.015)	-0.147*** (0.015)	-0.238*** (0.015)	-0.090*** (0.014)
Constant	13.977*** (0.011)	8.641*** (0.010)	14.088*** (0.011)	13.981*** (0.010)	8.667*** (0.009)
Observaciones	9,892	9,892	9,892	14,764	14,764
R ²	0.010	0.001	0.009	0.018	0.003
R ² ajustado	0.010	0.001	0.009	0.017	0.003
Error estándar residual	0.751 (df = 9890)	0.721 (df = 9890)	0.762 (df = 9890)	0.889 (df = 14762)	0.832 (df = 14762)
F Statistic	97.364*** (df = 1; 9890)	9.559*** (df = 1; 9890)	91.422*** (df = 1; 9890)	263.841*** (df = 1; 14762)	43.342*** (df = 1; 14762)

Nota:

*p<0.1; **p<0.05; ***p<0.01

Los resultados muestran evidencia de que las mujeres ganan menos que los hombres. Aunque existe cierta variación en los coeficientes de la variable *female*, todos son negativos y estadísticamente significativos, lo que indica pérdidas salariales para las mujeres.

Cabe señalar que en los resultados anteriores todos los coeficientes fueron estimados mediante mínimos cuadrados ordinarios. No obstante, es posible obtenerlos aplicando el Teorema de Frisch-Waugh-Lovell (FWL). Supongamos que queremos estimar el coeficiente de una variable X_1 en una regresión múltiple que también incluye una variable de control X_2 , en el siguiente modelo:

$$y = \beta_1 X_1 + \beta_2 X_2 + u$$

Para estimar β_1 usando el Teorema de Frisch-Waugh-Lovell, se siguen los siguientes pasos:

1. Regrese y sobre X_2 y obtenga los residuos.

Denotemos estos residuos como r_y :

$$r_y = y - \hat{y}_2 \quad \text{donde } \hat{y}_2 = X_2 \hat{\beta}_2$$

2. Regrese X_1 sobre X_2 y obtenga los residuos.

Denotemos estos residuos como r_{X_1} :

$$r_{X_1} = X_1 - \hat{X}_{1,2} \quad \text{donde } \hat{X}_{1,2} = X_2 \hat{\gamma}$$

3. Regrese los residuos r_y sobre r_{X_1} .

El coeficiente estimado será exactamente igual a $\hat{\beta}_1$ de la regresión original:

$$\hat{\beta}_1 = \frac{r'_{X_1} r_y}{r'_{X_1} r_{X_1}}$$

Este procedimiento permite estimar el efecto de X_1 sobre y , controlando por X_2 , sin

necesidad de realizar directamente la regresión múltiple completa. Además, resulta útil para reducir el costo computacional en aplicaciones con gran cantidad de variables.

Como ilustración de este procedimiento, estimamos el siguiente modelo mediante el método clásico de MCO y también aplicando el teorema de FWL:

$$\log(\omega) = \beta_1 + \beta_2 female + \beta_3 age + \beta_4 age^2 \quad (3)$$


Cuadro 6. Comparación de las estimaciones por MCO y FWL

	<i>Variable dependiente:</i>	
	log(y_ingLab_m) (1)	resid_ing (2)
female	-0.163*** (0.015)	
age	0.091*** (0.004)	
age_sqr	-0.001*** (0.00005)	
resid_fem		-0.163*** (0.017)
Constant	12.338*** (0.071)	-0.000 (0.007)
Observations	9,892	9,892
R ²	0.069	0.012
Adjusted R ²	0.069	0.012
Residual Std. Error	0.739 (df = 9888)	0.739 (df = 9890)
F Statistic	245.548*** (df = 3; 9888)	119.495*** (df = 1; 9890)
<i>Note:</i>		*p<0.1; **p<0.05; ***p<0.01

El Cuadro 6 muestra que los coeficientes de *female* y *resid_fem* son idénticos. Sin embargo, los errores estándar no lo son. Esto ocurre debido a la forma en que se realiza la estimación en dos etapas: al reducir el número de variables en la segunda ecuación, los grados de libertad utilizados también disminuyen.

Otra manera de estimar el error estándar es a través del método bootstrap. Este procedimiento consiste en realizar un remuestreo de la muestra n veces y reestimar el coeficiente en cada repetición. El error estándar se obtiene a partir de la dispersión de esta distribución de estimaciones.

Figura 4. Coeficiente de *female*



Nota: La figura muestra el histograma de los coeficientes de *female* obtenidos a través del bootstrap con 5000 remuestreos.

La Figura 4 muestra la distribución del coeficiente de *female*. Al calcular el error estándar, obtenemos un valor de 0.01472, prácticamente idéntico al obtenido mediante la estimación por MCO.

Al estimarnos el modelo 2, no hemos considerado ningún control. Es posible que existan variables omitidas influenciando nuestros resultados. De esta manera, a fin de verificar la robustez agregamos los siguientes controles a nuestra estimación:

- **Capital humano:** Incluimos edad y su cuadrado como aproximación a la experiencia laboral, así como el nivel educativo más alto alcanzado. Estas variables capturan diferencias en productividad potencial.
- **Intensidad laboral:** En las especificaciones con salarios mensuales, se consideran las horas usuales de trabajo y la existencia de un segundo empleo. En las especificaciones con salarios por hora, estas variables se omiten deliberadamente para evitar un ajuste redundante.
- **Características del empleo:** Incorporamos ocupación, tamaño de la firma, tipo de relación laboral, formalidad del empleo y la antigüedad en el puesto. Estos factores permiten aproximar la comparabilidad entre trabajos, tal como lo exige la noción de “igual trabajo”.

La estrategia empírica consiste en estimar primero la brecha salarial sin controles y, posteriormente, añadir secuencialmente los bloques de covariables. De este modo, se puede observar cómo evoluciona el coeficiente asociado a la variable de género, lo que permite interpretar en qué medida el diferencial incondicional se explica por diferencias observables en características de los trabajadores y de sus empleos. En esta parte estimamos apenas como variable dependiente la variable de ingreso de la ocupación principal por hora.

Nota: En la ecuación (5) se omitieron las variables relacionadas con el oficio y el número de personas que trabajan en la empresa.

Los resultados en el Cuadro 7 muestran que el coeficiente de *female* sigue siendo negativo y significativo. Además, la inclusión de controles incrementa la magnitud del coeficiente.

Cuadro 7. Resultados de las regresiones con controles

	Variable dependiente:				
	log(y_ingLab.m_ha)				
	(1)	(2)	(3)	(4)	(5)
female	-0.045*** (0.015)	-0.058*** (0.014)	-0.142*** (0.012)	-0.179*** (0.012)	-0.106*** (0.012)
age		0.068*** (0.004)	0.062*** (0.003)	0.068*** (0.003)	0.038*** (0.003)
age_sqr		-0.001*** (0.00004)	-0.001*** (0.00004)	-0.001*** (0.00004)	-0.0003*** (0.00003)
primarios incompleto			0.199** (0.094)	0.223** (0.093)	0.167** (0.076)
as.factor(primario completo)4			0.289*** (0.091)	0.303*** (0.090)	0.203*** (0.073)
as.factor(secundario incompleto)5			0.347*** (0.091)	0.355*** (0.089)	0.229*** (0.073)
as.factor(secundario completo)6			0.565*** (0.090)	0.575*** (0.088)	0.292*** (0.072)
as.factor(terciario)7			1.253*** (0.089)	1.238*** (0.088)	0.557*** (0.073)
totalHoursWorked				-0.009*** (0.0005)	-0.010*** (0.0004)
cuentaPropia					
microEmpresa					-0.392*** (0.044)
formal					0.261*** (0.015)
Constant	8.747*** (0.010)	7.392*** (0.068)	6.583*** (0.104)	6.940*** (0.104)	8.793*** (0.164)
Observations	9,892	9,892	9,891	9,891	9,891
R ²	0.001	0.046	0.335	0.358	0.576
Adjusted R ²	0.001	0.045	0.335	0.358	0.572
Residual Std. Error	0.727 (df = 9890)	0.711 (df = 9888)	0.593 (df = 9882)	0.583 (df = 9881)	0.476 (df = 9798)
F Statistic	9.317*** (df = 1; 9890)	158.028*** (df = 3; 9888)	623.580*** (df = 8; 9882)	612.986*** (df = 9; 9881)	144.719*** (df = 92; 9798)

Note:

*p<0.1; **p<0.05; ***p<0.01


El modelo con todos los controles indica que las mujeres llegan a ganar aproximadamente un 10 % menos que los hombres, dado que ambos tengan la misma experiencia, edad y ejerzan profesiones similares.

Un aspecto interesante sería estimar la edad pico en la que las mujeres alcanzarían su máximo salarial. Esto puede calcularse mediante un problema sencillo de maximización:

$$pico = -\frac{\beta_2}{2\beta_3},$$


donde β_2 es el coeficiente de age y β_3 es el coeficiente de age^2 .

Figura 5. Edad pico según nuestros modelos



La Figura 5 muestra los resultados de la edad pico. En general, los modelos indican que la edad pico estaría entre los 45 y 54 años. La inclusión de controles parece incrementar dicha edad. Cabe señalar que, al estimar la edad pico a partir de los coeficientes de MCO, no es posible calcular sus errores estándar ni los intervalos de confianza. Para generar dichos intervalos, empleamos el método bootstrap. En particular, remuestreamos los datos 2000 veces y registramos la distribución de la edad pico. Con esta distribución construimos el intervalo de confianza al 5 % para nuestros modelos.

Figura 6. Intervalos de confianza de la edad pico



La Figura 6 muestra los resultados de los intervalos de confianza. Como era de esperar, la inclusión de más controles amplía dichos intervalos; sin embargo, el incremento no supera los 2 años con respecto al valor central de la estimación.

5. Prediciendo Salarios

Para evaluar y comparar el desempeño predictivo, reportamos el Error Cuadrático Medio de Predicción (RMSE) de las especificaciones de los dos puntos anteriores y lo contrastamos con cinco modelos adicionales que incorporan no linealidades y mayor complejidad. Los modelos seleccionados fueron los siguientes:

- **Modelo 1 (Edad cuadrática):**

$$\ln w_i = \beta_0 + \beta_1 \text{Edad}_i + \beta_2 \text{Edad}_i^2 + u_i$$

- **Modelo 2 (Brecha salarial por género incondicional):**

$$\ln w_i = \beta_0 + \beta_1 \text{Mujer}_i + u_i$$

- **Modelo 3 (Brecha salarial por género condicional):**

$$\begin{aligned} \ln w_i = & \beta_0 + \beta_1 \text{Mujer}_i + \beta_2 \text{Edad}_i + \beta_3 \text{Edad}_i^2 + \beta_4 \text{Educ}_i \\ & + \beta_5 \text{Horas}_i + \beta_6 \text{Microemp}_i + \beta_7 \text{Formal}_i + \beta_8 \text{TamañoFirma}_i + \beta_9 \text{Oficio}_i + u_i \end{aligned}$$

- **Modelo 4 (Modelo 3 con polinomio de tercer grado en edad e interacciones de este polinomio con el resto de controles):**

$$\begin{aligned} \ln w_i = & \beta_0 + \sum_{m=1}^3 \beta_1^m \text{Edad}_i^m + \beta_2 \text{Mujer}_i + \beta_3 \text{Educ}_i + \beta_4 \text{Horas}_i \\ & + \beta_5 \text{Microemp}_i + \beta_6 \text{Formal}_i + \beta_7 \text{TamañoFirma}_i + \beta_8 \text{Oficio}_i \\ & + \sum_{m=0}^3 \left[\gamma_1^m (\text{Mujer}_i \text{Edad}_i^m) + \gamma_2^m (\text{Educ}_i \text{Edad}_i^m) + \gamma_3^m (\text{Horas}_i \text{Edad}_i^m) \right. \\ & \quad + \gamma_4^m (\text{Microemp}_i \text{Edad}_i^m) + \gamma_5^m (\text{Formal}_i \text{Edad}_i^m) + \gamma_6^m (\text{TamañoFirma}_i \text{Edad}_i^m) \\ & \quad \left. + \gamma_7^m (\text{Oficio}_i \text{Edad}_i^m) \right] + u_i \end{aligned}$$

- **Modelo 5 (Modelo 4 pero con el polinomio de edad de grado 5):**

$$\begin{aligned} \ln w_i = & \beta_0 + \sum_{m=1}^5 \beta_1^m \text{Edad}_i^m + \sum_j \beta_j \text{Control}_{ji} \\ & + \sum_{m=0}^5 \sum_j \gamma_j^m (\text{Control}_{ji} \text{Edad}_i^m) + u_i \end{aligned}$$

Controles: Mujer, Educ, Horas, Microemp, Formal, TamañoFirma, Oficio.

- **Modelo 6 (Modelo 3 añadiendo Educación Terciaria como control):**

$$\begin{aligned}\ln w_i = & \beta_0 + \beta_1 \text{Mujer}_i + \beta_2 \text{Edad}_i + \beta_3 \text{Edad}_i^2 + \beta_4 \text{Educ}_i \\ & + \beta_5 \text{Horas}_i + \beta_6 \text{Microemp}_i + \beta_7 \text{Formal}_i + \beta_8 \text{Tamaño}_i + \beta_9 \text{Oficio}_i \\ & + \beta_{10} \text{College}_i + u_i\end{aligned}$$

- **Modelo 7 (Modelo 6 con polinomios de grado 5 para edad y total de horas trabajadas):**

$$\begin{aligned}\ln w_i = & \beta_0 + \sum_{m=1}^5 \beta_1^m \text{Edad}_i^m + \sum_{m=1}^5 \beta_2^m \text{Horas}_i^m \\ & + \beta_3 \text{Mujer}_i + \beta_4 \text{Educ}_i + \beta_5 \text{Microemp}_i + \beta_6 \text{Formal}_i + \beta_7 \text{Tamaño}_i + \beta_8 \text{Oficio}_i + \beta_9 \text{College}_i + u_i\end{aligned}$$

- **Modelo 8 (Modelo 6 con polinomios de grado 3 para edad y educación, así como interacciones de estos polinomios con el resto de controles):**

$$\begin{aligned}\ln w_i = & \beta_0 + \sum_{m=1}^3 \beta_1^m \text{Edad}_i^m + \sum_{m=1}^3 \beta_2^m \text{Horas}_i^m \\ & + \sum_{m=0}^3 \sum_j \gamma_{1j}^m (\text{Edad}_i^m \text{Control}_{ji}) + \sum_{m=0}^3 \sum_j \gamma_{2j}^m (\text{Horas}_i^m \text{Control}_{ji}) + u_i\end{aligned}$$

Controles: Mujer, Educ, Microemp, Formal, Tamaño, Oficio, College.

Como se puede observar, para explorar nuevos modelos predictivos propusimos añadir polinomios a las variables continuas disponibles (edad y horas trabajadas), así como interactuar dichos polinomios con el resto de predictores del modelo. De esta manera, capturamos posibles relaciones no lineales y heterogeneidades en los retornos a la edad y a las horas según las características individuales y del mercado laboral. Esta estrategia nos permite evaluar si una mayor flexibilidad funcional se traduce en mejoras de desempeño predictivo. Los resultados de RMSE para los 8 modelos se presentan a continuación.

Cuadro 8. Comparación del RMSE entre los modelos seleccionados

Modelo	RMSE
1	0.67766
2	0.69275
3	0.44956
4	0.44769
5	0.54028
6	0.44956
7	0.44763
8	0.62034

Al comparar los ocho modelos estimados, observamos que las especificaciones más sim-

ples (Modelos 1 y 2) presentan los RMSE más altos, con valores de 0.678 y 0.693 respectivamente. Esto indica que los modelos que consideran únicamente edad o género, sin incorporar más información, son poco precisos en la predicción de los salarios. A medida que incluimos más controles y formas funcionales flexibles, el RMSE disminuye de manera importante, lo que evidencia la relevancia de capturar la heterogeneidad de las variables individuales y laborales para disminuir el sesgo.


Por otro lado, los Modelos 3, 4, 6 y 7 alcanzan los RMSE más bajos, todos en torno a 0.448–0.450. Dentro de este grupo, destacan especialmente el Modelo 4 y el Modelo 7. El Modelo 4 introduce polinomios cúbicos en la edad junto con interacciones con variables clave como género, educación, formalidad u oficio, lo que permite capturar diferencias en cómo la edad impacta los salarios dependiendo de estas características. El Modelo 7, por su parte, amplía la flexibilidad al incorporar polinomios de quinto grado tanto en edad como en horas trabajadas, además de los controles seleccionados para el Modelo 3, lo que le da capacidad para representar no linealidades más complejas en dos dimensiones fundamentales del mercado laboral. El hecho de que ambos modelos obtengan RMSE muy similares a los de especificaciones más sencillas (3 y 6) indica que gran parte de la capacidad predictiva ya está capturada por los controles, pero que la incorporación de estas formas funcionales adicionales ayuda a refinar la predicción en los márgenes donde las relaciones son más complejas.

Por último, los Modelos 5 y 8 muestran un RMSE más alto (0.540 y 0.620, respectivamente) en comparación con los modelos de complejidad intermedia. Esto refleja que, aunque las interacciones y polinomios de alto grado pueden capturar patrones no lineales, también pueden inducir sobreajuste y empeorar la capacidad predictiva fuera de muestra. En conjunto, nuestros resultados resaltan la importancia de un balance: los modelos con controles adecuados y cierta flexibilidad no lineal son los que logran el mejor desempeño, mientras que un aumento excesivo en complejidad resulta contraproducente.

Ahora, para la especificación con el menor error de predicción, conviene examinar las observaciones con los errores más altos (en valor absoluto) para determinar si esos desajustes se deben a limitaciones del modelo o, por el contrario, a posibles subdeclaraciones de ingreso por parte de algunos individuos. Con ese fin, analizamos la distribución de los errores.

Al examinar la distribución de los errores de predicción en la muestra de prueba, observamos que estos se concentran fuertemente alrededor de cero y siguen una forma aproximadamente simétrica. Esto indica que, en promedio, el modelo no presenta un sesgo sistemático: predice tanto por encima como por debajo del valor observado con una frecuencia similar. La mayoría de los errores se ubica en un rango relativamente estrecho, lo que refleja un buen ajuste global, aunque se identifican algunas observaciones en las colas de la distribución. Estas colas corresponden a los casos en los que el modelo “falla” con mayor magnitud y, por lo tanto, resultan los más relevantes de analizar en detalle.

Figura 7. Histograma del error de predicción en el "testing set"



Al concentrarnos en las colas de la distribución —específicamente los percentiles 1 y 99— encontramos que estas observaciones extremas comparten ciertas características diferenciales frente al resto de la muestra. En particular, tienden a registrar menos horas trabajadas (43.97 en promedio, lo cual está por debajo del percentil 25 en la muestra total), menor grado de formalidad y una mayor presencia de trabajadores en microempresas. Esto sugiere que los errores más grandes no provienen de perfiles totalmente atípicos, sino de segmentos del mercado laboral donde la variabilidad en los ingresos es mayor y más difícil de capturar con el modelo. Además, se trata de grupos menos presentes en la muestra, lo que limita el ajuste y explica en parte por qué el modelo no logra predecirlos con precisión.

Dentro de estas 60 observaciones extremas, identificamos cuatro casos con un leverage aproximadamente tres veces menor que la media, pero que se ubican por encima del percentil 99 de los errores de predicción. Este patrón resulta llamativo porque se trata de individuos con perfiles relativamente comunes —es decir, no atípicos en sus características observables— cuyos ingresos declarados superan de forma importante lo que el modelo predice. En este sentido, podrían constituir alertas para la DIAN, ya que los errores no parecen deberse a rarezas en el perfil, sino a posibles discrepancias entre lo esperado y lo reportado.

En conjunto, nuestro análisis muestra que la mayor parte de los errores extremos se asocian a segmentos con baja formalidad, microempresas y menos horas trabajadas, lo cual refleja limitaciones del modelo en grupos poco representados y con alta variabilidad de ingresos. Sin embargo, los pocos casos con leverage bajo y errores muy grandes merecen especial atención, ya que no se explican por perfiles raros y podrían corresponder a situaciones en las que los ingresos declarados se apartan de manera significativa de lo que cabría esperar. Así, los errores de predicción resultan útiles tanto para identificar limitaciones del

Cuadro 9. Descriptivas — Observaciones en las colas de la distribución del error

Variable	N = 60
Age	36.98 (13.41)
Horas trabajadas	43.97 (19.89)
Educación	
1	1/60 (1.7 %)
3	0/60 (0 %)
4	4/60 (6.7 %)
5	5/60 (8.3 %)
6	13/60 (22 %)
7	37/60 (62 %)
Mujer	35/60 (58 %)
Micro empresa	23/60 (38 %)
Formal	32/60 (53 %)
Tamaño firma	
1	5/60 (8.3 %)
2	18/60 (30 %)
3	4/60 (6.7 %)
4	11/60 (18 %)
5	22/60 (37 %)
Educación Terciaria	13/60 (22 %)

Nota: Para variables continuas, media (desv. est.). Para categóricas, frecuencia (porcentaje).

modelo como para señalar posibles candidatos de investigación por parte de la DIAN.

Finalmente, con el fin de contrastar la estabilidad de nuestros resultados, aplicamos la técnica de Leave-One-Out Cross-Validation (LOOCV) a los dos modelos que previamente habían mostrado el menor error predictivo bajo el enfoque de validation set. Esta comparación nos permite evaluar si el desempeño de los modelos se mantiene cuando cada observación es excluida sucesivamente, lo cual otorga una medida más robusta de error fuera de muestra y se relaciona estrechamente con la sensibilidad del modelo frente a observaciones influyentes.

Para los dos modelos con mejor desempeño en validación simple, encontramos que el RMSE mediante el enfoque de validation set fue de 0.4477 en el Modelo 4 y de 0.4476 en el Modelo 7. Cuando aplicamos Leave-One-Out Cross-Validation (LOOCV), el error cambió ligeramente: el Modelo 4 obtuvo un RMSE de 0.4440, mientras que el Modelo 7 alcanzó 0.4504. Esto significa que, con LOOCV, el Modelo 4 mejora marginalmente su desempeño, mientras que el Modelo 7 empeora.

Las diferencias entre ambos métodos son pequeñas, pero informativas. El hecho de que el Modelo 4 mantenga un error estable e incluso algo menor bajo LOOCV sugiere que es más robusto y generaliza mejor a nuevas observaciones. En contraste, el Modelo 7 parece más sensible al esquema de validación: aunque su desempeño era casi idéntico al del Modelo 4 con validation set, en LOOCV su error aumenta, lo que indica mayor variabilidad y posible sobreajuste a la partición inicial de entrenamiento/validación.

En el caso del Modelo 4, la complejidad proviene de la combinación de polinomios cúbicos en la edad con interacciones con todas las demás variables del modelo. Esta estrategia le permite ajustar la relación entre edad y salario de manera diferenciada según género, educación, formalidad u oficio. Al incorporar la heterogeneidad de forma más estructurada, el modelo logra mantener un desempeño estable incluso bajo un esquema exigente como el LOOCV, donde cada observación se deja por fuera en la estimación.

Por su parte, el Modelo 7 introduce polinomios de quinto grado en la edad y en las horas trabajadas, lo que genera curvas más sensibles y con oscilaciones más marcadas, en especial en los extremos del soporte. Al no estar acompañada de tantas interacciones, esta flexibilidad resulta menos organizada y más vulnerable a la exclusión de observaciones. En consecuencia, el error de predicción aumenta con LOOCV, lo que sugiere que el Modelo 7 es más inestable frente a datos atípicos o poco frecuentes.

En conclusión, el vínculo con la estadística de influencia es directo: en LOOCV, cada observación se deja por fuera una vez, y aquellas con alto leverage o con residuos grandes (PRESS residuals) afectan más el error total. En este sentido, es probable que el Modelo 7 sea más vulnerable a observaciones influyentes, lo que explica el aumento en su RMSE bajo LOOCV. El Modelo 4, en cambio, parece menos sensible a estas observaciones, lo

que lo convierte en una especificación más estable frente a posibles outliers o casos de alto apalancamiento.

Referencias

- Albouy, D., Christensen, P., and Sarmiento-Barbieri, I. (2020). Unlocking amenities: Estimating public good complementarity. *Journal of Public Economics*, 182:104110.
- McMillen, D., Sarmiento-Barbieri, I., and Singh, R. (2019). Do more eyes on the street reduce crime? evidence from chicago’s safe passage program. *Journal of urban economics*, 110:1–25.
- Nikolov, P. (2020). Writing tips for economics research papers.