

PS1 - Equipo 03

Catalina Leal Rojas, Lucas Daniel Carrillo Aguirre, Lucas Eduardo Veras
Costa, Maria Paula Basto Lozano

7 de septiembre de 2025

1. Introducción

Poner acá la introducción

2. Datos

■ Fuente de los datos:

La información utilizada para este estudio fue obtenida desde el “*Reporte de Medición de Pobreza Monetaria y Desigualdad*”, correspondiente a la Gran Encuesta Integrada de Hogares (GEIH) hecha por el Departamento Administrativo Nacional de Estadística (DANE) en el año 2018.

Este reporte busca hacer una caracterización de la población sobre rubros como los ingresos, el estrato, la edad, el sexo, la cantidad de horas trabajadas, entre otros.

■ Web Scraping:

Los datos necesarios para el análisis están consignados en una página web (https://ignaciomsarmiento.github.io/GEIH2018_sample/) que dirige a diez enlaces diferentes para cada una de las particiones de la base de datos original. Así, la forma más pertinente para extraer los datos resultó ser el método de raspado web o web scraping. Sin embargo, debido a que la página está construida en formato Java Script, las instrucciones revisadas a lo largo del curso para este método fueron insuficientes.

Para acceder a la fuente cruda de las tablas de cada uno de los diez chunks de datos fue necesario hacer una revisión de los elementos de la página por medio de la herramienta “Inspección” integrada en el explorador Google Chrome. Allí, en el panel de elementos en la ventana de “Red” se identificó un apartado con la fuente HTML de la página, que dirigía al mismo enlace de arriba, con un “[pages/geih_page_1.html](#)” adicional para la primera página. Agregando esa terminación sobre cada una de las otras nueve páginas y se hizo entonces un web scraping común para un HTML con

tablas. Este proceso de extracción se hizo iterativamente sobre cada uno de los enlaces y se compiló en una tabla combinada con 32,177 observaciones para 178 variables diferentes.

■ Limpieza de los datos:

Para hacer que los datos fuesen adecuados para hacer el análisis central de este trabajo, a saber, la modelación del salario por hora en esta muestra poblacional específica, fue necesario hacer un proceso de depuración e imputación de datos de la siguiente manera.

Primero, se redujo la muestra poblacional a los individuos mayores a 18 años de edad, que son los que están en edad de trabajar y tienen datos de salario disponibles; así como también se eliminaron los individuos que trabajaran por cuenta propia toda vez que la contabilidad de sus ingresos es inexacta y difícil de rastrear. Esto también implicó la eliminación de observaciones que tuvieran salarios de cero o nulos.

Segundo, se eliminaron, de la muestra inicial de 178, todas las variables que en cada una de las observaciones tuvieran consistentemente valores faltantes o valores idénticos. Además, se desestimaron todas las variables que tuvieran valores faltantes en más del 60 % de las observaciones. Estos dos pasos fueron necesarios para evitar utilizar observaciones y variables que podían no aportar nada a la base más que ruido.

Después de estos dos pasos, se hizo la imputación de datos para cada uno de los valores faltantes en la base de datos resultante. Esto se hizo por medio de dos métodos. El primero implicó identificar todas las variables categóricas de la muestra, que eran todas aquellas que se correspondían con la indagación de salarios de los individuos (por ejemplo, preguntas de respuestas binarias de sí o no, o de respuestas con un rango del 1 al 3). Luego de que se hizo esto, se calculó la moda de las observaciones en esas variables para todos los individuos que compartieran el mismo estrato social, y los valores faltantes se imputaron con ella. Esto, entendiendo que es más probable que individuos que compartan condiciones socioeconómicas similares puedan tener características en sus ingresos comparables.

El segundo método implicó identificar las variables numéricas, que eran todas aquellas que tenían valores en magnitud monetaria, como los ingresos, los auxilios y las deducciones. A los valores faltantes de estas variables se les aplicó el método de K Vecinos más Cercanos (*o K-Nearest Neighbors*) que busca las similitudes entre las observaciones de la base e identifica, por medio de un algoritmo de aprendizaje supervisado, los k vecinos más cercanos para cada una (en este caso los 5 más cercanos). Así, con los valores de los vecinos, se imputaron las observaciones con valores faltantes en dichas variables.


Lo último que se hizo para la organización de la base de datos fue reemplazar con los valores del percentil 97.5 todos los valores de las observaciones de las variables de ingreso que se ubicaran más allá de ese umbral. Esto para evitar que esas variables, que suelen tener una dispersión importante en ese último segmento poblacional, tuviesen un impacto indeseado sobre la estadística descriptiva de la muestra.

- Estadística descriptiva de los datos:

Tabla


Histogramas

Figura 1. Salario por Hora



Nota: La figura muestra el histograma del salario por hora de la muestra. La línea roja presenta la media y la azul la mediana.

Figura 2. Logaritmo del Salario por Hora



Nota: La figura muestra el histograma del logaritmo natural del salario por hora de la muestra. La línea roja presenta la media y la azul la mediana.

3. Perfil edad-salario

En esta sección analizaremos la relación entre el perfil edad-salario. En primer lugar, es importante discutir qué medida de ingreso utilizar. La base de datos de la GEIH incluye diversas medidas, como ingreso por primas monetarias, ingreso mensual, ingreso usual en el mes e ingreso efectivo en el mes, entre otras.

En los estudios que analizan el perfil salarial de edad, es común emplear el ingreso por hora, ya que permite aislar el efecto de las horas trabajadas en el mes, lo cual podría sesgar los resultados. Asimismo, suele utilizarse la variable de ingreso en logaritmos, lo que mejora la interpretabilidad del coeficiente estimado, que pasaría a representar cuánto impacta, en términos porcentuales, una unidad adicional de la variable independiente sobre el ingreso, en este caso un año adicional en la edad.

Se estimó el siguiente modelo para identificar el perfil edad-salario de las observaciones de la muestra.

$$\ln w_i = \beta_1 + \beta_2 Age_i + \beta_3 Age_i^2 + u_i \quad (1)$$

Donde w_i es el ingreso salarial por hora del individuo i y Age_i es su edad. Se realizó la estimación del modelo con las diferentes medidas de ingreso salarial real y nominal por hora:

Cuadro 1. Perfil de salario-edad

	<i>Dependent variable:</i>	
	log(y_salary_m.hu)	log(y_total_m.ha)
	(1)	(2)
age	0.059*** (0.003)	0.066*** (0.003)
I(age^2)	-0.001*** (0.00004)	-0.001*** (0.00004)
Constant	7.407*** (0.064)	7.393*** (0.065)
Observations	9,892	9,892
R ²	0.040	0.045
Adjusted R ²	0.040	0.045
Residual Std. Error (df = 9889)	0.671	0.677
F Statistic (df = 2; 9889)	206.012***	235.041***
<i>Note:</i> *p<0.1; **p<0.05; ***p<0.01		

■ Interpretación de los coeficientes:

De acuerdo con los resultados de las dos regresiones, el perfil salarial según la edad tienen la misma forma funcional, es decir una curva cóncava. En concreto, el término lineal de la edad muestra el efecto directo de “sumar un año”, mientras que el término cuadrático ($edad^2$) captura cómo que existen efectos diferenciados sobre el salario en

edades diferentes de la vida, es decir que la relación entre la edad y el salario no es lineal.

El sumar un año de edad incrementa 5.9 % y 6.6 % el salario (el efecto directo) tomando como el salario real y nominal por hora respectivamente. Ambos coeficientes estimados son significativos estadísticamente y positivos lo que indica en primera instancia un efecto directo positivo de la edad sobre el salario. El coeficiente relacionado con la edad al cuadrado captura esa relación no lineal. Tanto para el modelo con el salario real como el nominal el coeficiente de la edad cuadrática es negativo lo que indica la concavidad de la relación, es decir que hasta un punto la relación entre edad y salario o es positiva y luego es negativa, en ambos modelos el término es negativo y estadísticamente significativo.

Para estimar la semielesticidad de la edad sobre el logaritmo del salario solucionamos la condición de primer orden. Luego un año adicional de edad aumenta porcentualmente el salario en:

$$100 \times (\beta_2 + 2 \times \beta_3 \times edad) \%$$

La semielesticidad de para las edades de 18 , 25, 45 y 50 años se presentan en el cuadro 2. Como se observa, entre más joven más aporta un año más de edad en el incremento porcentual del salario, va decreciendo e incluso se vuelve negativo el aporte desde edad más avanzada lo que se denomina edad pico.

Cuadro 2. Semielesticidad del salario sobre el ingreso

Edad	Salario Real	Salario Nominal
18	3.588	3.957
25	2.676	2.927
35	1.372	1.456
45	0.069	-0.015
50	-0.582	-0.750

El coeficiente constante para ambos modelos es positivo y significativo, y representa el valor del logaritmo del salario cuando la edad es cero. Aunque este valor no tiene una interpretación económica directa, no se trabaja con 0 años, por lo que es el término que ajusta el modelo para la relación entre edad y salario dentro del rango de edades observado en la muestra.

■ Ajuste de la muestra:

Para analizar el ajuste de los modelos dentro de la muestra, se presenta los siguientes estadísticos como el error estándar (RSE), el error cuadrático medio (RMSE), el R^2 ajustado, estadístico F y criterios de información Akaike (AIC) y bayeciano (BIC).

Los resultados muestran que ambos modelos ofrecen un desempeño explicativo limitado pero estadísticamente significativo. El coeficiente de determinación ajustado R^{2*} es de 0.040 en el modelo del salario real y de 0.045 en el del salario nominal, lo que

Cuadro 3. Medidas de ajuste para los modelos de salario por edad


Modelo	RSE	RMSE	R^2_*	F	AIC	BIC
Salario real	0.671	0.671	0.040	206.012	20186.076	20214.874
Salario nominal	0.677	0.677	0.045	235.041	20360.186	20388.984

indica que aproximadamente el 4–4,5 % de la variación en el logaritmo del salario se explica únicamente por la edad y su cuadrado. El error estándar residual (RSE), que estima la desviación promedio de los residuos ajustando por los grados de libertad, es de 0,671 y 0,677 respectivamente, mientras que el RMSE, que se calcula sobre el total de observaciones, coincide numéricamente con esos valores debido al gran tamaño muestral. Ambos modelos presentan un F estadístico alto y significativo (206.0 y 235.0), que el modelo es globalmente estadísticamente significativo. Finalmente, los criterios de información AIC y BIC son menores en el modelo con salario nominal, lo que sugiere que este ofrece un ajuste más eficiente penalizando la complejidad del modelo.

■ **Gráfico de ingreso salarial, edad pico y su intervalo de confianza:**

A continuación se presenta el gráfico de los valores predichos con cada modelo:

Figura 3. Gráfico del logaritmo de salarios predichos, intervalo de confianza y edad pico



La edad pico se refiere a la edad en la cual el logaritmo del salario alcanza su máximo. Y se obtiene derivando la función del logaritmo del salario e igualando a cero , es

decir que la edad pico se calcula como:

$$edad_pico = -\frac{\beta_2}{2\beta_3}$$

Luego, para cada modelo la edad pico es:


- **Modelo salario real:** 45.53
- **Modelo salario nominal:** 44.89

Luego por bootstrap no paramétrico se estimaron las edades pico para cada modelo con mil remuestreos con reemplazo (R). En cada réplica se re estimó cada modelo obteniendo los coeficientes y luego calculando la edad pico para las R repeticiones. A partir de la distribución empírica de las R edades pico, se calcularon los intervalos de confianza al 95 % con el método de percentil, es decir que los límites corresponden a los cuartiles 2.25 % y 97.5 % de la distribución bootstrap de la edad pico. Los respectivos intervalos de confianza son:

- **Modelo salario real:** (43.74 , 46.21)
- **Modelo salario nominal:** (44.25 , 47.05)

La figura muestra, para cada modelo (nominal y real), la distribución bootstrap de la edad pico: el histograma en azul claro representa la frecuencia de las edades pico re-muestreadas y la curva en azul oscuro es la densidad kernel asociada. Además se agregó: la media de la edad pico por bootstrap para cada modelo, que es representado con la línea vertical morada ; y, los intervalos de confianza para cada modelo en la línea punteada gris. En conjunto, la gráfica permite comparar visualmente la localización y la dispersión de las edades pico entre ambos modelos, dado las densidades se solapan y los intervalos percentiles son similares, se la evidencia indica que las edades pico no difieren de forma sustantiva.

Figura 4. Distribución estimada e intervalos de confianza edad pico



4. La brecha género-salario

En esta sección analizaremos la relación entre ingresos y género femenino. En primer lugar, es importante discutir qué medida de ingreso utilizar. La base de datos de la GEIH incluye diversas medidas, como ingreso por primas monetarias, ingreso mensual, ingreso usual en el mes e ingreso efectivo en el mes, entre otras.

En los estudios que analizan la brecha salarial entre hombres y mujeres, es común emplear el ingreso por hora, ya que permite aislar el efecto de las horas trabajadas en el mes, lo cual podría sesgar los resultados. Asimismo, suele utilizarse la variable de ingreso en logaritmos, lo que mejora la interpretabilidad del coeficiente estimado, que pasaría a representar cuánto impacta, en términos porcentuales, una unidad adicional de la variable independiente sobre el ingreso.

También es importante señalar que nos interesa comparar únicamente a hombres y mujeres que trabajan. Por lo tanto, el análisis se centra en los individuos ocupados de la muestra.

Inicialmente estimamos el siguiente modelo:

$$\log(\omega) = \beta_0 + \beta_1 Female + u \quad (2)$$

El Cuadro 4 presenta los resultados de la estimación por mínimos cuadrados ordinarios utilizando diversas medidas de ingreso. *ysalarym* corresponde al ingreso nominal de la ocupación principal, *ysalarymha* al salario por hora de la ocupación principal, *yingLabm* al ingreso proveniente de todas las ocupaciones, *ytotalm* al ingreso total proveniente de ocupaciones e ingresos independientes, y *ytotalmha* al ingreso total de ocupaciones e independientes medido por hora.

Cuadro 4. Resultados del modelo incondicional

	Variable dependiente:				
	log(ysalarym)	log(ysalarymha)	log(yingLabm)	log(ytotalm)	log(ytotalmha)
	(1)	(2)	(3)	(4)	(5)
female	-0.149*** (0.015)	-0.045*** (0.015)	-0.147*** (0.015)	-0.238*** (0.015)	-0.090*** (0.014)
Constant	13.977*** (0.011)	8.641*** (0.010)	14.088*** (0.011)	13.981*** (0.010)	8.667*** (0.009)
Observaciones	9,892	9,892	9,892	14,764	14,764
R ²	0.010	0.001	0.009	0.018	0.003
R ² ajustado	0.010	0.001	0.009	0.017	0.003
Error estándar residual	0.751 (df = 9890)	0.721 (df = 9890)	0.762 (df = 9890)	0.889 (df = 14762)	0.832 (df = 14762)
F Statistic	97.364*** (df = 1; 9890)	9.559*** (df = 1; 9890)	91.422*** (df = 1; 9890)	263.841*** (df = 1; 14762)	43.342*** (df = 1; 14762)

Nota:

*p<0.1; **p<0.05; ***p<0.01

Los resultados muestran evidencia de que las mujeres ganan menos que los hombres. Aunque existe cierta variación en los coeficientes de la variable *female*, todos son negativos y estadísticamente significativos, lo que indica pérdidas salariales para las mujeres.

Cabe señalar que en los resultados anteriores todos los coeficientes fueron estimados mediante mínimos cuadrados ordinarios. No obstante, es posible obtenerlos aplicando el Teorema de Frisch-Waugh-Lovell (FWL). Supongamos que queremos estimar el coeficiente de una variable X_1 en una regresión múltiple que también incluye una variable de control X_2 , en el siguiente modelo:

$$y = \beta_1 X_1 + \beta_2 X_2 + u$$

Para estimar β_1 usando el Teorema de Frisch-Waugh-Lovell, se siguen los siguientes pasos:

1. Regrese y sobre X_2 y obtenga los residuos.

Denotemos estos residuos como r_y :

$$r_y = y - \hat{y}_2 \quad \text{donde } \hat{y}_2 = X_2 \hat{\beta}_2$$

2. Regrese X_1 sobre X_2 y obtenga los residuos.

Denotemos estos residuos como r_{X_1} :

$$r_{X_1} = X_1 - \hat{X}_{1,2} \quad \text{donde } \hat{X}_{1,2} = X_2 \hat{\gamma}$$

3. Regrese los residuos r_y sobre r_{X_1} .

El coeficiente estimado será exactamente igual a $\hat{\beta}_1$ de la regresión original:

$$\hat{\beta}_1 = \frac{r'_{X_1} r_y}{r'_{X_1} r_{X_1}}$$

Este procedimiento permite estimar el efecto de X_1 sobre y , controlando por X_2 , sin

necesidad de realizar directamente la regresión múltiple completa. Además, resulta útil para reducir el costo computacional en aplicaciones con gran cantidad de variables.

Como ilustración de este procedimiento, estimamos el siguiente modelo mediante el método clásico de MCO y también aplicando el teorema de FWL:

$$\log(\omega) = \beta_1 + \beta_2 female + \beta_3 age + \beta_4 age^2 \quad (3)$$


Cuadro 5. Comparación de las estimaciones por MCO y FWL

	<i>Variable dependiente:</i>	
	log(y_ingLab_m) (1)	resid_ing (2)
female	-0.163*** (0.015)	
age	0.091*** (0.004)	
age_sqr	-0.001*** (0.00005)	
resid_fem		-0.163*** (0.017)
Constant	12.338*** (0.071)	-0.000 (0.007)
Observations	9,892	9,892
R ²	0.069	0.012
Adjusted R ²	0.069	0.012
Residual Std. Error	0.739 (df = 9888)	0.739 (df = 9890)
F Statistic	245.548*** (df = 3; 9888)	119.495*** (df = 1; 9890)
<i>Note:</i>		*p<0.1; **p<0.05; ***p<0.01

El Cuadro 5 muestra que los coeficientes de *female* y *resid_fem* son idénticos. Sin embargo, los errores estándar no lo son. Esto ocurre debido a la forma en que se realiza la estimación en dos etapas: al reducir el número de variables en la segunda ecuación, los grados de libertad utilizados también disminuyen.

Otra manera de estimar el error estándar es a través del método bootstrap. Este procedimiento consiste en realizar un remuestreo de la muestra n veces y reestimar el coeficiente en cada repetición. El error estándar se obtiene a partir de la dispersión de esta distribución de estimaciones.

Figura 5. Coeficiente de *female*



Nota: La figura muestra el histograma de los coeficientes de *female* obtenidos a través del bootstrap con 5000 remuestreos.

La Figura 5 muestra la distribución del coeficiente de *female*. Al calcular el error estándar, obtenemos un valor de 0.01472, prácticamente idéntico al obtenido mediante la estimación por MCO.

Al estimarnos el modelo 2, no hemos considerado ningún control. Es posible que existan variables omitidas influenciando nuestros resultados. De esta manera, a fin de verificar la robustez agregamos los siguientes controles a nuestra estimación:

- **Capital humano:** Incluimos edad y su cuadrado como aproximación a la experiencia laboral, así como el nivel educativo más alto alcanzado. Estas variables capturan diferencias en productividad potencial.
- **Intensidad laboral:** En las especificaciones con salarios mensuales, se consideran las horas usuales de trabajo y la existencia de un segundo empleo. En las especificaciones con salarios por hora, estas variables se omiten deliberadamente para evitar un ajuste redundante.
- **Características del empleo:** Incorporamos ocupación, tamaño de la firma, tipo de relación laboral, formalidad del empleo y la antigüedad en el puesto. Estos factores permiten aproximar la comparabilidad entre trabajos, tal como lo exige la noción de “igual trabajo”.

La estrategia empírica consiste en estimar primero la brecha salarial sin controles y, posteriormente, añadir secuencialmente los bloques de covariables. De este modo, se puede observar cómo evoluciona el coeficiente asociado a la variable de género, lo que permite interpretar en qué medida el diferencial incondicional se explica por diferencias observables en características de los trabajadores y de sus empleos. En esta parte estimamos apenas como variable dependiente la variable de ingreso de la ocupación principal por hora.

Nota: En la ecuación (5) se omitieron las variables relacionadas con el oficio y el número de personas que trabajan en la empresa.

Los resultados en el Cuadro 6 muestran que el coeficiente de *female* sigue siendo negativo y significativo. Además, la inclusión de controles incrementa la magnitud del coeficiente.

Cuadro 6. Resultados de las regresiones con controles

	Variable dependiente:				
	log(y_ingLab.m_ha)				
	(1)	(2)	(3)	(4)	(5)
female	-0.045*** (0.015)	-0.058*** (0.014)	-0.142*** (0.012)	-0.179*** (0.012)	-0.106*** (0.012)
age		0.068*** (0.004)	0.062*** (0.003)	0.068*** (0.003)	0.038*** (0.003)
age_sqr		-0.001*** (0.00004)	-0.001*** (0.00004)	-0.001*** (0.00004)	-0.0003*** (0.00003)
primarios incompleto			0.199** (0.094)	0.223** (0.093)	0.167** (0.076)
as.factor(primario completo)4			0.289*** (0.091)	0.303*** (0.090)	0.203*** (0.073)
as.factor(secundario incompleto)5			0.347*** (0.091)	0.355*** (0.089)	0.229*** (0.073)
as.factor(secundario completo)6			0.565*** (0.090)	0.575*** (0.088)	0.292*** (0.072)
as.factor(terciario)7			1.253*** (0.089)	1.238*** (0.088)	0.557*** (0.073)
totalHoursWorked				-0.009*** (0.0005)	-0.010*** (0.0004)
cuentaPropia					
microEmpresa					-0.392*** (0.044)
formal					0.261*** (0.015)
Constant	8.747*** (0.010)	7.392*** (0.068)	6.583*** (0.104)	6.940*** (0.104)	8.793*** (0.164)
Observations	9,892	9,892	9,891	9,891	9,891
R ²	0.001	0.046	0.335	0.358	0.576
Adjusted R ²	0.001	0.045	0.335	0.358	0.572
Residual Std. Error	0.727 (df = 9890)	0.711 (df = 9888)	0.593 (df = 9882)	0.583 (df = 9881)	0.476 (df = 9798)
F Statistic	9.317*** (df = 1; 9890)	158.028*** (df = 3; 9888)	623.580*** (df = 8; 9882)	612.986*** (df = 9; 9881)	144.719*** (df = 92; 9798)

Note:

*p<0.1; **p<0.05; ***p<0.01


El modelo con todos los controles indica que las mujeres llegan a ganar aproximadamente un 10 % menos que los hombres, dado que ambos tengan la misma experiencia, edad y ejerzan profesiones similares.

Un aspecto interesante sería estimar la edad pico en la que las mujeres alcanzarían su máximo salarial. Esto puede calcularse mediante un problema sencillo de maximización:

$$pico = -\frac{\beta_2}{2\beta_3},$$


donde β_2 es el coeficiente de age y β_3 es el coeficiente de age^2 .

Figura 6. Edad pico según nuestros modelos



La Figura 6 muestra los resultados de la edad pico. En general, los modelos indican que la edad pico estaría entre los 45 y 54 años. La inclusión de controles parece incrementar dicha edad. Cabe señalar que, al estimar la edad pico a partir de los coeficientes de MCO, no es posible calcular sus errores estándar ni los intervalos de confianza. Para generar dichos intervalos, empleamos el método bootstrap. En particular, remuestreamos los datos 2000 veces y registramos la distribución de la edad pico. Con esta distribución construimos el intervalo de confianza al 5 % para nuestros modelos.

Figura 7. Intervalos de confianza de la edad pico



La Figura 7 muestra los resultados de los intervalos de confianza. Como era de esperar, la inclusión de más controles amplía dichos intervalos; sin embargo, el incremento no supera los 2 años con respecto al valor central de la estimación.

5. Prediciendo Salarios

Referencing tables is very easy you can do the following: In Table ?? ...

Citing papers is easier, for example [Albouy et al. \(2020\)](#) shows that crime around parks.
For many papers in parenthesis [Albouy et al. \(2020\)](#), [McMillen et al. \(2019\)](#)

6. ?

7. Conclusion

Referencias

- Albouy, D., Christensen, P., and Sarmiento-Barbieri, I. (2020). Unlocking amenities: Estimating public good complementarity. *Journal of Public Economics*, 182:104110.
- McMillen, D., Sarmiento-Barbieri, I., and Singh, R. (2019). Do more eyes on the street reduce crime? evidence from chicago’s safe passage program. *Journal of urban economics*, 110:1–25.
- Nikolov, P. (2020). Writing tips for economics research papers.