

Datos: extracción, descripción y análisis

8 de septiembre de 2025

Fuente, Web Scraping y limpieza

- **Fuente de los datos.** Reporte de Medición de Pobreza Monetaria y Desigualdad (GEIH 2018, DANE). Contiene información de ingresos, estrato, edad, sexo y horas trabajadas, entre otras.
- **Web scraping.** Los datos públicos se obtuvieron desde `ignaciomsarmiento.github.io/GEIH2018_sample/` navegando las 10 páginas de *chunks* (`pages/geih_page_{1..10}.html`) y extrayendo las tablas HTML.
- **Limpieza y preparación.**
 - Filtro: ocupados, ≥ 18 años, sin salarios nulos/cero; se excluye cuenta propia.
 - Depuración de variables: se eliminan columnas con todo NA / constante y con $>60\%$ de NA.
 - Imputación: (i) categóricas por moda dentro de *estrato*; (ii) numéricas con KNN ($k = 5$).
 - Tratamiento de colas en ingresos: recorte en el percentil 97.5.
- **Muestra final.** 9,892 observaciones y 19 variables de interés.

Estadística descriptiva

(a) Variables numéricas

Variable	N	Media	Desv. Est.	Min	Max
Salario mensual	9,892	1,610,063	1,537,099	20,000	7,892,292
Salario por hora	9,892	8,121.29	8,099.11	326.67	41,470.34
ln(Salario)	9,892	8.71	0.69	5.79	10.63
Horas trabajadas	9,892	48.34	12.25	1.00	130.00
Edad	9,892	36.24	12.02	18.00	86.00
Mujer (1 = Sí)	9,892	0.50	0.50	0.00	1.00
Trabaja en microempresa (1 = Sí)	9,892	0.23	0.42	0.00	1.00
Trabajo formal (1 = Sí)	9,892	0.77	0.42	0.00	1.00

(b) Variables categóricas


Variable	Categoría	Descripción	Frecuencia	Porcentaje
Nivel educativo	7	Educación terciaria	4,478	45.27 %
Oficio	39	Apoyo administrativo y logístico	814	8.23 %
Tamaño de empresa	5	> 50 empleados	5,107	51.63 %
Tipo de empleo	1	Empleado de empresa particular	8,757	88.53 %

Nota: Panel (a) reporta N, media, desviación estándar, mínimo y máximo. Panel (b) reporta categoría modal, su descripción, frecuencia y porcentaje.

Distribuciones del salario

- Los salarios se concentran en la parte más baja de la distribución, entre los \$3,000 y los \$9,000 pesos por hora.
- Los salarios más altos siguen empujando las estadísticas hacia arriba, a pesar del corte de ingresos en el percentil 97.5. Se observa una cola con casi 500 individuos con ingresos mayores a \$40,000 por hora.
- Esto sugiere una importante desigualdad salarial en un contexto de brechas socioeconómicas pronunciadas como Bogotá.

Salario por hora



Logaritmo natural del salario

