

Predicción del salario

Catalina Leal Rojas, Lucas Daniel Carrillo Aguirre, Lucas Eduardo
Veras Costa, Maria Paula Basto Lozano

September 9, 2025

- **Modelo 1 (Edad cuadrática):**

$$\ln w_i = \beta_0 + \beta_1 \text{Edad}_i + \beta_2 \text{Edad}_i^2 + u_i$$

- **Modelo 2 (Brecha salarial por género incondicional):**

$$\ln w_i = \beta_0 + \beta_1 \text{Mujer}_i + u_i$$

- **Modelo 3 (Brecha salarial por género condicional):**

$$\begin{aligned} \ln w_i = & \beta_0 + \beta_1 \text{Mujer}_i + \beta_2 \text{Edad}_i + \beta_3 \text{Edad}_i^2 + \beta_4 \text{Educ}_i \\ & + \beta_5 \text{Horas}_i + \beta_6 \text{Microemp}_i + \beta_7 \text{Formal}_i + \beta_8 \text{TamañoFirma}_i \\ & + \beta_9 \text{Oficio}_i + u_i \end{aligned}$$

- **Modelo 4 (Modelo 3 con polinomio de tercer grado en edad e interacciones de este polinomio con el resto de controles):**

$$\begin{aligned}\ln w_i = & \beta_0 + \sum_{m=1}^3 \beta_1^m \text{Edad}_i^m + \beta_2 \text{Mujer}_i + \beta_3 \text{Educ}_i + \beta_4 \text{Horas}_i \\ & + \beta_5 \text{Microemp}_i + \beta_6 \text{Formal}_i + \beta_7 \text{TamañoFirma}_i + \beta_8 \text{Oficio}_i \\ & + \sum_{m=0}^3 \left[\gamma_1^m (\text{Mujer}_i \text{Edad}_i^m) + \gamma_2^m (\text{Educ}_i \text{Edad}_i^m) + \gamma_3^m (\text{Horas}_i \text{Edad}_i^m) \right. \\ & \quad + \gamma_4^m (\text{Microemp}_i \text{Edad}_i^m) + \gamma_5^m (\text{Formal}_i \text{Edad}_i^m) + \gamma_6^m (\text{TamañoFirma}_i \text{Edad}_i^m) \\ & \quad \left. + \gamma_7^m (\text{Oficio}_i \text{Edad}_i^m) \right] + u_i\end{aligned}$$

- **Modelo 5 (Modelo 4 pero con el polinomio de edad de grado 5):**

$$\begin{aligned}\ln w_i = & \beta_0 + \sum_{m=1}^5 \beta_1^m \text{Edad}_i^m + \sum_j \beta_j \text{Control}_{ji} \\ & + \sum_{m=0}^5 \sum_j \gamma_j^m (\text{Control}_{ji} \text{Edad}_i^m) + u_i\end{aligned}$$

Controles: Mujer, Educ, Horas, Microemp, Formal, TamañoFirma, Oficio.

- **Modelo 6 (Modelo 3 añadiendo Educación Terciaria como control):**

$$\begin{aligned}\ln w_i = & \beta_0 + \beta_1 \text{Mujer}_i + \beta_2 \text{Edad}_i + \beta_3 \text{Edad}_i^2 + \beta_4 \text{Educ}_i \\ & + \beta_5 \text{Horas}_i + \beta_6 \text{Microemp}_i + \beta_7 \text{Formal}_i + \beta_8 \text{Tamaño}_i + \beta_9 \text{Oficio}_i \\ & + \beta_{10} \text{College}_i + u_i\end{aligned}$$

- **Modelo 7 (Modelo 6 con polinomios de grado 5 para edad y total de horas trabajadas):**

$$\begin{aligned}\ln w_i = & \beta_0 + \sum_{m=1}^5 \beta_1^m \text{Edad}_i^m + \sum_{m=1}^5 \beta_2^m \text{Horas}_i^m \\ & + \beta_3 \text{Mujer}_i + \beta_4 \text{Educ}_i + \beta_5 \text{Microemp}_i + \beta_6 \text{Formal}_i + \beta_7 \text{Tamaño}_i \\ & + \beta_8 \text{Oficio}_i + \beta_9 \text{College}_i + u_i\end{aligned}$$

- **Modelo 8 (Modelo 6 con polinomios de grado 3 para edad y educación, así como interacciones de estos polinomios con el resto de controles):**

$$\ln w_i = \beta_0 + \sum_{m=1}^3 \beta_1^m \text{Edad}_i^m + \sum_{m=1}^3 \beta_2^m \text{Horas}_i^m \\ + \sum_{m=0}^3 \sum_j \gamma_{1j}^m (\text{Edad}_i^m \text{Control}_{ji}) + \sum_{m=0}^3 \sum_j \gamma_{2j}^m (\text{Horas}_i^m \text{Control}_{ji}) + u_i$$

Controles: Mujer, Educ, Microemp, Formal, Tamaño, Oficio, College.

Modelo	RMSE
1	0.67766
2	0.69275
3	0.44956
4	0.44769
5	0.54028
6	0.44956
7	0.44763
8	0.62034

Table: Comparación del RMSE entre los modelos seleccionados

- A medida que incluimos más controles y formas funcionales flexibles, el RMSE disminuye de manera importante, lo que evidencia la relevancia de capturar la heterogeneidad de las variables individuales y laborales para disminuir el sesgo.
- Los modelos 4 (polinomio de grado 3 en edad e interacciones con todos los controles) y 7 (polinomio de grado 5 en edad y horas trabajadas) tuvieron el menor RMSE, aunque estos valores no están lejos de los RMSE correspondientes a los modelos 3 y 6.
- Esto indica que gran parte de la capacidad predictiva ya está capturada por los controles, pero que la incorporación de estas formas funcionales adicionales ayuda a refinar la predicción en los márgenes donde las relaciones son más complejas.
- Los modelos 5 y 8 son un ejemplo de overfitting.

Análisis de los errores en el modelo 7




Figure: Histograma del error de predicción en el "testing set"

Análisis de los errores en el modelo 7

- Distribución centrada en 0 y simétrica: el modelo no presenta un sesgo sistemático, este predice tanto por encima como por debajo del valor observado con una frecuencia similar.
- Para las observaciones con errores más altos (percentiles 1 y 99 de la distribución) tienden relativamente a
 - Trabajar menos horas (43.97 frente a 48)
 - ser menos formales en promedio (53% vs 77%)
 - trabajar más en microempresas (38% vs 23%)
- Esto sugiere que los errores más grandes provienen de perfiles ligeramente distintos del promedio, es decir, de segmentos del mercado laboral donde la variabilidad en los ingresos es mayor y su representación es menor, lo que hace más difícil predecir exactamente el salario.

- Metodología válida para regresión polinomial:

$$CV_{(n)} = \frac{1}{n} \sum_{i=1}^n \left(\frac{y_i - \hat{y}_i}{1 - h_i} \right)^2 ,$$

LOOCV (modelos 4 y 7)

	Modelo 4	Modelo 7
RMSE VS	0.4477	0.4476
RMSE LOOCV	0.4440	0.4504

Table: Comparación de errores de predicción

LOOCV (modelos 4 y 7)

- El hecho de que el Modelo 4 mantenga un error estable e incluso algo menor bajo LOOCV sugiere que es más robusto y generaliza mejor a nuevas observaciones. En contraste, el Modelo 7 parece más sensible al esquema de validación.
- En el modelo 4 la inclusión de un menor grado en el polinomio (3 vs 5) y además interacciones con los controles permite incluir heterogeneidad de forma más estructurada.
- Por su parte, el Modelo 7 introduce polinomios de quinto grado, lo que genera curvas más sensibles y con oscilaciones más marcadas, en especial en los extremos del soporte. Al no estar acompañada de interacciones, esta flexibilidad resulta menos organizada y más vulnerable a la exclusión de observaciones.
- Es probable que el Modelo 7 resulta más sensible a observaciones influyentes, lo que eleva su RMSE con LOOCV, mientras que el Modelo 4 muestra mayor estabilidad frente a outliers o alto apalancamiento.